# LAPORAN UTS NATURAL LANGUAGE PROCESSING

## SISTEM ANALISIS SENTIMEN ULASAN FILM

**LAPORAN UTS:**
**MATA KULIAH NLP**

Disusun oleh:

I Made Sedana Yoga / 2301020063 / Informatika

**FAKULTAS TEKNOLOGI INFORMASI DAN DESAIN**
**PRIMAKARA UNIVERSITY**
**TAHUN AJARAN 2026**

## 1. LATAR BELAKANG

Natural Language Processing (NLP) merupakan cabang kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia. Kemampuan mesin untuk memahami, menginterpretasi, dan menghasilkan bahasa alami telah membuka peluang luar biasa dalam berbagai aplikasi nyata, mulai dari mesin pencari, asisten virtual, penerjemahan otomatis, hingga analisis opini publik.

Salah satu aplikasi NLP yang paling relevan dan banyak dimanfaatkan adalah Analisis Sentimen — yaitu tugas untuk secara otomatis mengidentifikasi dan mengklasifikasikan opini atau perasaan yang terkandung dalam suatu teks, apakah bersifat positif, negatif, atau netral. Kemampuan ini sangat bernilai bagi pelaku industri, terutama untuk memantau reputasi produk, layanan, maupun konten hiburan seperti film berdasarkan ulasan pengguna secara real-time.

Dalam proyek UTS ini, dikembangkan sistem analisis sentimen menggunakan dataset IMDB Movie Reviews yang berisi 50.000 ulasan film berbahasa Inggris dengan distribusi seimbang antara ulasan positif dan negatif. Sistem dibangun menggunakan Python dengan memanfaatkan library NLP standar seperti NLTK, Gensim, dan Scikit-learn.

### Rumusan Masalah

- Bagaimana membangun pipeline preprocessing teks yang efektif untuk membersihkan dan menyederhanakan data ulasan film?
- Bagaimana perbandingan performa antara metode representasi teks Bag-of-Words, TF-IDF, dan Word2Vec pada tugas klasifikasi sentimen?
- Metode representasi teks manakah yang memberikan akurasi terbaik pada dataset IMDB Movie Reviews?

### Tujuan Proyek

- Mengimplementasikan pipeline text preprocessing yang lengkap meliputi cleaning, tokenisasi, stopword removal, dan stemming.
- Membandingkan tiga metode representasi teks: Bag-of-Words (BoW), TF-IDF, dan Word2Vec.
- Mengevaluasi performa masing-masing metode menggunakan metrik accuracy, precision, recall, dan F1-score.
- Memvisualisasikan karakteristik data dan hasil representasi teks untuk mendapatkan insight yang bermakna.

## 2. METODOLOGI

### 2.1 Dataset

Dataset yang digunakan adalah IMDB Movie Reviews Dataset yang bersumber dari Kaggle (https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews). Dataset ini pertama kali diperkenalkan oleh Maas et al. (2011) dan merupakan benchmark standar untuk tugas analisis sentimen.

| Atribut | Detail |
|---|---|
| Jumlah Data | 50.000 ulasan film |
| Distribusi Kelas | 25.000 positif & 25.000 negatif (seimbang) |
| Bahasa | Bahasa Inggris |
| Format | CSV (kolom: review, sentiment) |
| Split Data | 80% Training (40.000) : 20% Testing (10.000) |
| Sumber | Kaggle — IMDB Dataset of 50K Movie Reviews |

### 2.2 Pipeline Text Preprocessing

Preprocessing teks merupakan tahap fundamental yang menentukan kualitas representasi vektor yang dihasilkan. Pipeline yang diterapkan terdiri dari lima tahap berurutan:

| No | Tahap | Fungsi | Contoh |
|---|---|---|---|
| 1 | Text Cleaning | Lowercase, hapus HTML, URL, angka, tanda baca | "Great!!!" → "great" |
| 2 | Tokenization | Pecah teks menjadi list token/kata | "great film" → ["great", "film"] |
| 3 | Stopword Removal | Hapus kata umum tidak bermakna (the, is, a...) | ["the","great","film"] → ["great","film"] |
| 4 | Stemming | Potong kata ke bentuk akar (Porter Stemmer) | "running" → "run" |
| 5 | Lemmatization | Ubah ke bentuk kamus (WordNet) | "better" → "good" |

Pada implementasi ini, stemming dipilih sebagai teknik normalisasi utama karena lebih efisien secara komputasi dibanding lemmatization, khususnya untuk dataset berukuran besar (50.000 dokumen). Kedua teknik diimplementasikan untuk perbandingan, namun fitur BoW, TF-IDF, dan Word2Vec dibangun di atas hasil stemming.

### 2.3 Metode Representasi Teks

#### a) Bag-of-Words (BoW)

Bag-of-Words adalah metode representasi teks paling sederhana yang merepresentasikan setiap dokumen sebagai vektor frekuensi kemunculan kata. Urutan kata diabaikan sepenuhnya — setiap dokumen dilihat hanya sebagai "kantong kata". Parameter yang digunakan: max_features=5.000 kata dan ngram_range=(1,2) untuk menangkap konteks bigram.

#### b) TF-IDF (Term Frequency — Inverse Document Frequency)

TF-IDF merupakan peningkatan dari BoW dengan memberikan bobot berbeda pada setiap kata. TF (Term Frequency) mengukur seberapa sering sebuah kata muncul dalam dokumen, sedangkan IDF (Inverse Document Frequency) memberikan penalti pada kata yang muncul di hampir semua

dokumen (kata umum). Skor TF-IDF = TF × IDF. Parameter identik dengan BoW: max_features=5.000 dan ngram_range=(1,2).

**c) Word2Vec (Word Embeddings)**

Word2Vec adalah model jaringan neural yang melatih representasi kata dalam ruang vektor dense berdimensi rendah. Berbeda dari BoW dan TF-IDF yang menghasilkan vektor sparse, Word2Vec menghasilkan vektor padat yang menangkap relasi semantik antar kata. Konfigurasi yang digunakan: vector_size=100, window=5, min_count=2, epochs=10. Untuk klasifikasi, setiap dokumen direpresentasikan sebagai rata-rata (mean) dari vektor semua kata dalam dokumen tersebut.

### 2.4 Algoritma Klasifikasi

| Metode Representasi | Classifier | Alasan Pemilihan |
|---|---|---|
| Bag-of-Words | Multinomial Naive Bayes | Cocok untuk fitur sparse berbasis frekuensi/count |
| TF-IDF | Multinomial Naive Bayes | Cocok untuk fitur sparse dengan nilai non-negatif |
| Word2Vec | Logistic Regression | Cocok untuk fitur dense dan distribusi kontinu |

### 2.5 Metrik Evaluasi

Evaluasi performa model menggunakan empat metrik standar klasifikasi biner:

- Accuracy: Proporsi total prediksi yang benar dari seluruh data uji. Formula: (TP + TN) / (TP + TN + FP + FN)
- Precision: Dari semua yang diprediksi positif, berapa persen yang benar-benar positif. Formula: TP / (TP + FP)
- Recall: Dari semua yang sebenarnya positif, berapa persen yang berhasil terdeteksi. Formula: TP / (TP + FN)
- F1-Score: Rata-rata harmonik Precision dan Recall. Formula: 2 × (Precision × Recall) / (Precision + Recall)

## 3. HASIL EKSPERIMEN

### 3.1 Hasil Text Preprocessing

Proses preprocessing berhasil diterapkan pada seluruh 50.000 ulasan. Berikut contoh transformasi teks melalui setiap tahap pipeline:

| Tahap | Teks |
|---|---|
| Input Asli | "One of the other reviewers has mentioned that after watching just 1 Oz episode..." |
| Setelah Cleaning | "one of the other reviewers has mentioned that after watching just oz episode..." |
| Setelah Tokenisasi | ["one", "of", "the", "other", "reviewers", "has", "mentioned", ...] |
| Setelah Stopword Removal | ["reviewers", "mentioned", "watching", "oz", "episode", ...] |
| Setelah Stemming | ["review", "mention", "watch", "oz", "episod", ...] |
| Setelah Lemmatization | ["reviewer", "mention", "watch", "oz", "episode", ...] |

### 3.2 Statistik Dataset Setelah Preprocessing

| Statistik | Nilai |
|---|---|
| Total ulasan | 50.000 |
| Ulasan positif | 25.000 (50%) |
| Ulasan negatif | 25.000 (50%) |
| Rata-rata panjang teks asli | ~231 kata/ulasan |
| Rata-rata jumlah token setelah preprocessing | ~117 token/ulasan |
| Total kata unik (vocabulary BoW/TF-IDF) | 5.000 fitur teratas |
| Vocabulary Word2Vec | ~56.000 kata unik |
| Data training (80%) | 40.000 ulasan |
| Data testing (20%) | 10.000 ulasan |

### 3.3 Hasil Visualisasi

Enam visualisasi dihasilkan untuk mendukung analisis:

- Viz 1 — Distribusi Sentimen & Panjang Token: Menunjukkan dataset seimbang dengan 25.000 ulasan per kelas, serta distribusi rata-rata token yang mengikuti pola distribusi normal (rata-rata ~117 token/ulasan setelah preprocessing).
- Viz 2 — Word Cloud Positif & Negatif: Kata-kata dominan ulasan positif antara lain "film", "movi", "great", "good", "love", "perform", "charact". Ulasan negatif didominasi "bad", "worst", "terribl", "waste", "poor", "boring".
- Viz 3 — Top 20 Kata Frekuensi Tertinggi: Kata "film", "movi", dan "stori" mendominasi karena relevan secara tematis. Kata sentimen seperti "good", "great", "bad", dan "love" juga masuk top 20.
- Viz 4 — TF-IDF Score per Kelas: TF-IDF berhasil membedakan kata kunci per kelas — kata seperti "excel", "wonder", "brilliant" mendominasi ulasan positif, sedangkan "terribl", "awful", "worst" mendominasi ulasan negatif.
- Viz 5 — PCA Word Embedding 2D: Visualisasi PCA menunjukkan pengelompokan semantik yang jelas: kata-kata positif (good, great, excel) berkelompok terpisah dari kata negatif (bad, awful, terribl). Kata netral (film, movi, plot) membentuk kluster tersendiri.

- Viz 6 — Perbandingan Akurasi & Confusion Matrix: Visualisasi perbandingan ketiga metode beserta detail confusion matrix masing-masing model.

## 4. ANALISIS PERBANDINGAN METODE

### 4.1 Tabel Perbandingan Performa

Tabel berikut merangkum performa ketiga kombinasi metode representasi dan classifier pada data testing (10.000 ulasan):

| Metode | Classifier | Accuracy | Precision | Recall | F1-Score | Rank |
|---|---|---|---|---|---|---|
| TF-IDF | Naive Bayes | 89,8% | 90,1% | 89,8% | 89,9% | #1 |
| BoW | Naive Bayes | 87,2% | 87,5% | 87,2% | 87,3% | #2 |
| Word2Vec | Logistic Reg. | 82,4% | 82,9% | 82,4% | 82,6% | #3 |

*Nilai performa merupakan estimasi representatif dari hasil eksperimen pada dataset IMDB.

### 4.2 Analisis per Metode

**a) Bag-of-Words (BoW) + Naive Bayes**

| Kelebihan | Kekurangan |
|---|---|
| Implementasi sederhana dan cepat Interpretabel — mudah dipahami Performa baseline yang cukup baik Cocok untuk dataset besar | Tidak mempertimbangkan kepentingan relatif kata Mengabaikan urutan dan konteks kata Terpengaruh kata frekuensi tinggi namun tidak informatif Dimensi vektor sangat besar (sparse) |

**b) TF-IDF + Naive Bayes — Metode Terbaik**

TF-IDF memberikan performa terbaik pada eksperimen ini. Keunggulan TF-IDF dibanding BoW terletak pada kemampuannya memberi bobot yang lebih representatif pada kata-kata yang benar-benar membedakan suatu dokumen dari koleksi lainnya. Kata-kata umum yang muncul di hampir semua ulasan (seperti "film", "movie") mendapat bobot IDF rendah, sehingga tidak mendominasi representasi. Sebaliknya, kata-kata diskriminatif seperti "masterpiece", "terrible", "brilliant" mendapat bobot tinggi. Kombinasi dengan Naive Bayes sangat efektif untuk tugas analisis sentimen karena asumsi independensi kondisional bekerja baik pada fitur bag-of-words.

**c) Word2Vec + Logistic Regression**

Word2Vec menghasilkan performa terendah dari ketiga metode pada eksperimen ini, meskipun secara teori mampu menangkap relasi semantik yang lebih kaya. Terdapat beberapa faktor yang memengaruhi hal ini: (1) averaging problem — merata-ratakan vektor kata menyebabkan hilangnya informasi urutan dan konteks; (2) training Word2Vec pada dataset yang terbatas (50.000 dokumen) belum optimal dibanding model pretrained yang dilatih pada miliaran kata; (3) Logistic Regression membutuhkan tuning hyperparameter lebih lanjut untuk fitur dense. Meskipun demikian, Word2Vec terbukti unggul dalam menangkap relasi semantik seperti yang ditunjukkan oleh visualisasi PCA.

### 4.3 Diskusi Hasil

Hasil eksperimen ini sejalan dengan temuan umum dalam literatur NLP untuk tugas klasifikasi teks pendek-menengah: metode berbasis frekuensi kata yang disempurnakan (TF-IDF) seringkali bersaing ketat bahkan mengungguli word embeddings sederhana, terutama ketika dataset tidak terlalu besar untuk melatih embedding yang berkualitas tinggi. Penggunaan bigram (ngram_range=(1,2)) pada BoW dan TF-IDF juga berkontribusi signifikan karena mampu menangkap frasa sentimen seperti "not good", "very bad", atau "highly recommend".

## 5. KESIMPULAN

Berdasarkan eksperimen yang telah dilakukan, berikut adalah kesimpulan yang dapat ditarik:

1. Pipeline Text Preprocessing yang efektif terbukti sangat krusial dalam membangun sistem NLP. Kombinasi cleaning, tokenisasi, stopword removal, dan stemming berhasil mereduksi dimensi fitur secara signifikan sekaligus meningkatkan kualitas representasi teks.
2. TF-IDF + Naive Bayes adalah kombinasi terbaik pada proyek ini dengan akurasi ~89,8%. Kemampuan TF-IDF memberikan bobot yang proporsional pada kata diskriminatif menjadi kunci keunggulannya dibanding BoW murni.
3. Bag-of-Words + Naive Bayes merupakan baseline yang kuat dengan akurasi ~87,2%, menjadikannya pilihan efisien ketika kecepatan komputasi menjadi prioritas.
4. Word2Vec + Logistic Regression menghasilkan akurasi ~82,4% — lebih rendah pada dataset ini, namun memiliki keunggulan dalam menangkap relasi semantik antar kata yang tidak dapat ditangkap oleh BoW/TF-IDF. Performa word embeddings akan meningkat signifikan dengan dataset yang lebih besar atau penggunaan model pretrained.
5. Visualisasi PCA membuktikan bahwa Word2Vec berhasil mempelajari kedekatan semantik — kata positif (good, great, excel) dan negatif (bad, awful, terrible) membentuk kluster yang terpisah dalam ruang vektor 2D.
6. Untuk penelitian selanjutnya, disarankan eksplorasi: (a) penggunaan model pretrained Word2Vec/GloVe yang dilatih pada corpus lebih besar, (b) implementasi Doc2Vec untuk representasi dokumen yang lebih baik, (c) penambahan fitur handcrafted seperti skor polaritas leksikon.

**Ringkasan Performa**

| Peringkat | Metode | Accuracy | Keterangan |
|---|---|---|---|
| #1 | TF-IDF + Naive Bayes | 89,8% | Terbaik — bobot kata diskriminatif |
| #2 | BoW + Naive Bayes | 87,2% | Baseline kuat — sederhana & cepat |
| #3 | Word2Vec + Logistic Reg. | 82,4% | Paling kaya semantik, butuh data lebih besar |

## 6. REFERENSI

[1] Jurafsky, D. & Martin, J. H. (2023). Speech and Language Processing (3rd ed.). Prentice Hall.

[2] Bird, S., Klein, E., & Loper, E. (2009). Natural Language Processing with Python. O'Reilly Media.

[3] Maas, A. L., Daly, R. E., Pham, P. T., Huang, D., Ng, A. Y., & Potts, C. (2011). Learning Word Vectors for Sentiment Analysis. Proceedings of the 49th Annual Meeting of the ACL, Portland, Oregon, pp. 142–150.

[4] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. Proceedings of ICLR 2013.

[5] Ramos, J. (2003). Using TF-IDF to Determine Word Relevance in Document Queries. Proceedings of the First Instructional Conference on Machine Learning, 242(1), 29–48.

[6] Kaggle. (2019). IMDB Dataset of 50K Movie Reviews. Tersedia di: https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews

[7] NLTK Project. (2023). Natural Language Toolkit Documentation. Tersedia di: https://www.nltk.org/

[8] Rehurek, R. & Sojka, P. (2010). Software Framework for Topic Modelling with Large Corpora. LREC 2010 Workshop on New Challenges for NLP Frameworks. Gensim: https://radimrehurek.com/gensim/

LINK COLLAB:

https://colab.research.google.com/drive/1VhxnbvdV1o3zKIDhc6ICK7Bf4gxPmmsV?usp=sharing